

多评分者软辅助监督的残差机制： 序数评分中的受控路由与错配检验

匿名投稿

摘要

多评分者软标签能够保留评分分歧，但其如何通过共享表示影响最终硬评分仍不清楚。本文研究硬主头-软辅助头（Hard-Main/Soft-Auxiliary, HMSA）范式，在保持部署头和推理接口不变的条件下，将软交叉熵精确分解为重复主目标项与有符号残差，并仅在辅助分支进入共享主干的反向路径上路由残差及其相对公共梯度的平行和正交分量。EduBench 固定划分的三个预定种子上，HMSA 将测试平均绝对误差（MAE）由 0.433 ± 0.009 降至 0.388 ± 0.003 。在开发集固定第 10 轮的五种子内部稳健性分析中，完整残差、正交残差和平行残差相对直接残差阻断臂的平均 Δ MAE 分别为 -0.0219 、 -0.0131 和 $+0.0005$ 。进一步的范数-正交约束匹配检验显示，样本-残差配对差值在 EduBench 上区间跨零；在预先冻结的 Soft-STS-15 测试中，三个种子方向一致，但平均 Δ NMAE 为 -0.00102 ，未达到 -0.00125 的本研究预设最小报告幅度。由于受控路由与普通 HMSA 未通过完整训练轨迹等价检验，本文识别的是当前路由、全局裁剪和独立训练制度下的机制候选及其边界，而非普通 HMSA 测试增益的方向性因果分解。

关键词：自动教育评审；多评分者监督；软标签；梯度几何；序数评分

1 引言

自动评审器已被用于教育内容生成、智能辅导和大规模质量控制。EduBench 在 12 个教育评价维度上构造任务专用评审器，并为每个“问题-回答-评价维度”条目保留三位人类评分者的判断 [1]。常规训练只使用聚合后的 1-5 分标签，因而把 $[4, 4, 4]$ 与 $[3, 4, 4]$ 都表示为同一个确定的 4 分；后者保留的 $3/4$ 边界信息没有进入监督目标。与此同时，只报告总体一致性还可能掩盖低分条目的严重高估，故本文同时考察整体误差与低分风险。

学习完整标注分布是利用人类标签变异的自然方式 [2, 3, 4]，但自动评分部署仍需输出单一分数。若同一个输出头既拟合经验分布又承担硬决策，训练目标与部署目标可能不完全一致。软标签多任务学习因此将聚合标签预测设为主任务，将标注分布预测设为辅助任务，并共享编码表示 [5]。本文以这一范式为分析对象：HMSA 的硬头学习部署所需的整数标签，软头仅在训练时学习评分分布，两项损失共同更新主干，推理只读取硬头。研究重点不是双头结构本身，而是软辅助目标通过共享主干产生增益的原因。

仅观察 HMSA 优于 Hard-only 仍不能识别其中的有效成分。收益可能来自额外输出头、一般多任务正则化、连续均分、梯度范数变化，或分歧残差所引入的新方向。本文围绕两个问题展开：**RQ1**，在受控路由实现中，软辅助目标相对重复主目标增加的残差，其完整、平行与正交分量分别对应怎样的开发集差值？**RQ2**，在控制当前窗口正交性与范数后，样本自身残差是否优于来自同

一硬标签层其他样本的错配残差？为回答这两个问题，本文依次使用标签内置换、连续均分辅助、主目标-残差分解、梯度几何干预以及跨任务错配检验。

本文的主要贡献如下：

- **数学分解与路由**。将软辅助交叉熵精确分解为重复主目标项与有符号残差，并实现只控制辅助梯度直接进入共享主干路径的受控路由。
- **受控机制检验**。构造相对公共梯度的平行/正交干预，以及保持当前窗口正交性和范数的样本错配控制。
- **受限实证发现**。区分普通 HMSA 的 EduBench 测试性能、开发集路由机制候选和 Soft-STS-15 配对边界，并同时报告轨迹不等价、全局裁剪混杂和未达预设最小幅度的结果。

2 相关工作

2.1 自动教育评审与低分风险

LLM-as-a-judge 已成为开放式生成评价的重要工具 [6, 7]。教育评价还需处理学习科学维度、学生错误和任务特定标准，MRBench 与 MathTutorBench 因而引入多维教学评价及人工标注 [8, 9]。已有研究同时观察到位置偏差、自偏好和过度自信等问题 [10, 11]。本文不重新比较提示式大模型评审器，而在固定任务专用评审器中研究多评分者监督的训练机制，并把低分严重高估作为风险画像而非新的优化目标。

2.2 人类标签变异与软标签学习

聚合标签可能掩盖主观判断、多个合理解释或系统性评分差异 [2, 3]。学习经验分布可保留少数意见，并避免把所有样本表示为完全确定的独热目标 [12, 4]；LeWiDi 系列共享任务推动了保留多重标注的统一评测 [13, 14]。Kurniawan 等在 6 个数据集、14 种训练方法和 6 类指标上的系统研究进一步表明，软标签或分解标注训练常具有竞争力，但最优方法依赖评测口径 [15]。评分分歧也可能来自有效变异、标注错误或信息不足，不能预先把所有不一致都解释为有用信号 [16, 17]。Fornaciari 等将标注分布预测作为聚合标签预测的辅助任务 [5]，Davani 等和 Rodríguez-Barroso 等则从个体评分者建模与分布式学习角度利用评分差异 [3, 18]。近期预印本《Same Target, Different Basins: Hard vs. Soft Labels for Annotator Distributions》还表明，即使随机硬标签投喂与软标签交叉熵具有相同的期望目标，不同投喂方式与样本-分布错配仍可能进入不同优化盆地 [19]。该工作改变分布的训练投喂形式；本文保持软头目标与部署路径不变，转而干预共享主干中的残差路由、平行/正交分量和范数-正交约束匹配的错配残差。本文不提出新的多评分者结构，而是通过这些受控干预分析软辅助监督的有效成分。

2.3 多任务梯度与优化几何

多任务学习通过共享表示联合优化相关目标 [20]，其中的梯度冲突、范数不平衡与投影操作已有广泛研究。PCGrad 投影冲突梯度，CAGrad 在平均目标与最差局部改善之间折衷，GradVac 调整任务间余弦相似性 [21, 22, 23]；针对辅助任务，梯度相似度可用于动态筛选辅助损失，ForkMerge

则从验证性能出发过滤有害更新 [24, 26]。Dery 等依据辅助更新对主任务损失的局部影响，将其分为有益、有害和中性方向 [25]；本文的分解则来自多评分者软目标与量化硬目标之间的精确代数关系，并进一步控制残差直接进入共享主干的路径及其样本配对。Hsieh 等把辅助目标写为双层约束问题，并以主梯度的指数移动平均维持小批量条件下的正交性 [27]。本文既不使用移动平均，也不提出新的优化器，而把单个完整累积窗口内的投影作为机制干预；因此其“正交”只描述裁剪前参数梯度，不能直接解释为长期优化轨迹或函数空间中的因果分离。

2.4 序数学习

序数任务不仅要求预测正确类别，还应考虑错误在等级轴上的距离。除阈值分解、距离敏感损失和单调约束外，软标签序数回归将距离结构编码为概率目标，标签分布学习还进一步约束单峰性或样本自适应性 [28, 29, 30, 31]。这些方法通常从单一等级构造平滑分布；本文的软目标来自同一样本的真实多评分者频数，研究问题也不是设计新的序数损失，而是分析该辅助分布经共享主干产生的梯度成分。MAE、Kendall τ_b 与二次加权 Kappa (QWK) 分别用于刻画距离误差、排序一致性和等级一致性。

2.5 外部多评分者序数任务

Soft-STS-15 基于 SemEval-2015 语义文本相似度数据，公开每个句对的五个序数评分，并用于研究均值聚合之外的分布建模 [32, 33]。本文不将其作为教育评价基准，也不追求 STS 的最优性能；它仅用于检验在英文、每条公开五个评分和六级标签条件下，样本自身的正交残差是否优于范数-正交约束匹配的错配控制。

3 任务与数据

3.1 多评分者序数目标

对于样本 i ，输入 x_i 为待评分文本及任务条件， m 位评分者从有序标签集合 $\mathcal{Y} = \{a, a+1, \dots, a+K-1\}$ 中给出 r_{ij} 。人类均分与经验分布为

$$\bar{r}_i = \frac{1}{m} \sum_{j=1}^m r_{ij}, \quad d_{ik} = \frac{1}{m} \sum_{j=1}^m \mathbb{I}(r_{ij} = k), \quad k \in \mathcal{Y}. \quad (1)$$

主任务将均分量化为 y_i 。EduBench 使用 1–5 级且 $m = 3$ ；在固定划分中，评分模式只有完全一致或相邻等级 2:1，均分不可能为半整数，因而四舍五入不存在平局，且 $y_i = \text{round}(\bar{r}_i)$ 同时等于众数。Soft-STS-15 使用 0–5 级且每条公开五个评分，主目标为 $y_i = \lfloor \bar{r}_i + 0.5 \rfloor$ ；它不保证等于众数、中位数或某个公开评分。

例如 EduBench 的 $[3, 4, 4]$ 产生 $y = 4$ 和 $d = (0, 0, \frac{1}{3}, \frac{2}{3}, 0)$ 。在当前 EduBench 中，经验分布与连续均分一一对应，故不能声称分布包含均分之外的额外标签信息；它们的差异只可能来自目标参数化与损失几何。

表1先概括两个数据集的任务差异与实验用途，随后分别说明具体划分与评测口径。

表 1 EduBench 与 Soft-STS-15 的数据和评估设置。Soft-STS-15 用于跨任务边界检验，不构成第二个教育评分复现实验。

属性	EduBench	Soft-STS-15
任务	问题-回答-评价维度的教育质量评分	英文句对语义相似度
公开评分/等级	每条 3 个评分；1-5 级	每条公开 5 个评分；0-5 级
划分规模 (训练/开发/测试)	2,654/664/2,218	4,734/1,578/1,578
划分离隔单位	固定三元组划分	句子连接成分（跨划分零重叠） 五个公开评分的均值量化； 不保证为众数
主目标	三个评分均值四舍五入；亦为众数	硬头概率期望连续分
主预测	硬头 arg max 整数分	硬头概率期望连续分
实验用途	评分性能与机制分析	跨任务检验样本-残差配对

3.2 EduBench

EduBench 的输入由问题、生成回答和评价维度拼接，训练、开发与测试分别包含 2,654、664 和 2,218 个条目。本文使用经“问题-回答-评价维度”三元组隔离校验的固定划分，以三元组为数据单位，不另行施加问题级去重；因此同一问题可能出现在不同划分中，结果衡量的是三元组级评分表现，不据此主张对全新问题或回答的严格泛化。当前划分文件的可核验标识见补充材料。开发集和测试集分别包含 184 和 163 个问题簇；这里的问题簇只是配对自助重采样的统计单位，数量不要求与条目数或划分规模成比例。所有方法使用相同的数据划分和输入，不加入生成模型身份或额外自动评分。训练集中 1,169 条为三人一致，1,485 条为相邻等级 2:1 分歧；测试标签 1-5 的样本数分别为 56、47、194、720 和 1,201。由于低分样本明显较少，除总体指标外，本文还报告分等级召回率和低分严重高估率（真实标签不高于 2、预测至少为 4）。为保持方法比较的一致性，不使用重采样或类别权重。

3.3 Soft-STS-15

Soft-STS-15 包含 7,890 个英文句对，每条保留公开数据文件中的五个 0-5 整数评分；本文不声称这五个公开评分覆盖原始采集的全部评分者意见。本文只由这五个评分计算经验分布、均分与量化主目标，不使用数据发布方另附的聚合金标准字段；发布文件中的 `gs_score` 字段不进入任何训练目标或评测指标。根据句子连接成分构造固定的 60/20/20 划分，得到 4,734/1,578/1,578 条和 3,109/1,057/1,057 个连接成分；任一句子、规范化句对及其连接成分均不跨划分。开发集与测试集的成分大小中位数均为 1、95 分位数为 3，最大成分含 47 条（2.98%）。规范化规则、划分算法、逐划分标签分布、输入模板与清单哈希见补充材料。错配映射仅由训练集构造，模型选择和训练轮次均在测试评估前确定。




图 1 HMSA 的训练与部署路径。图中为 EduBench 五分类版本；Soft-ST5-15 使用结构相同的六分类版本。硬头承担主任务和最终评分，软头仅在训练阶段拟合多评分者分布；两项损失均更新共享主干，推理时删除软头。图中 CE 的参数顺序与正文一致：目标分布在前，logit 在后。

4 从性能配置到机制干预

4.1 Hard-only、单头软监督与 HMSA

共享主干输出最后一个非填充词元表示 h_i 。Hard-only 以无偏置线性头产生 K 类 logit（未归一化类别得分） $z_i^{(h)}$ ，损失为

$$\mathcal{L}_{\text{hard}} = -\log \text{softmax}(z_i^{(h)})_{y_i}. \quad (2)$$

EduBench 的预测为硬头 argmax 。两个单头基线分别为：Direct-soft 令同一部署头直接拟合 d_i ；Single-head mix 拟合固定混合目标 $0.5e_{y_i} + 0.5d_i$ 。这两个固定配置用于检验直接软化部署目标能否复现双头收益，不代表对所有混合系数和单头软监督方法的穷尽比较。

HMSA 在同一主干上增加参数独立的软头 $\text{logit } z_i^{(s)}$ ，并用初始硬头深拷贝初始化，以避免额外随机初始化成为混杂因素；其软目标采用交叉熵（cross-entropy, CE）：

$$\mathcal{L}_{\text{soft}} = -\sum_{k \in \mathcal{Y}} d_{ik} \log \text{softmax}(z_i^{(s)})_k, \quad \mathcal{L} = \mathcal{L}_{\text{hard}} + \mathcal{L}_{\text{soft}}. \quad (3)$$

两项损失共同更新主干，但分别更新各自的头；模型选择、最终评分和正文指标只读取硬头。辅助头可在部署时删除，故 HMSA 改变训练表示而不改变最终输出接口。图1展示该路径。

4.2 粗粒度替代解释

标签内置换（Shuffled-soft）在每个硬标签分层内以固定双射重排软目标，保持类别条件目标多重集、熵分布、结构和优化设置，仅破坏样本与评分分布的原始对应；2,654 个训练条目中有 56.14% 实际换成不同目标。MeanAux 则保持双头容量和硬头路径，以软头概率的期望分数 $\mu_i = \sum_k k \text{softmax}(z_i^{(m)})_k$ 拟合 $\bar{r}_i$ ，使用 $\beta = 1.0$ 的 Smooth L1 损失。该对照同时改变目标参数化和损失，因而只能判断固定连续均分方案能否复现 HMSA，不能单独区分概率约束与交叉熵的作用。

4.3 主目标-残差分解

令 e_y 为主目标的独热向量, z 为辅助头 logit, 并记 $\text{CE}(q, z) = -\sum_k q_k \log \text{softmax}(z)_k$, 则有精确恒等式

$$\text{CE}(d, z) = \text{CE}(e_y, z) + (e_y - d)^\top z. \quad (4)$$

该恒等式成立是因为 d 与 e_y 的分量和均为 1, 展开对数 softmax 后的 log-sum-exp 项相消。相应的 logit 梯度为

$$\underbrace{p - d}_{\text{软目标梯度}} = \underbrace{p - e_y}_{\text{主目标重复项}} + \underbrace{e_y - d}_{\text{有符号残差}}. \quad (5)$$

对于 $[3, 4, 4]$, 残差为 $\frac{1}{3}(e_4 - e_3)$; 单独最小化相应线性项时, 它倾向于减小类别 4 相对类别 3 的 logit 间隔, 三人一致时残差为零。这里的两个向量首先定义在辅助头 logit 空间。经辅助头和共享主干的向量-雅可比累积后, 分别记为主目标重复项 C_B 与残差项 R_B 。硬主任务自身产生主干梯度 $G_B^{(h)}$; 因此后文作为投影基准的完整公共梯度是

$$G_B^{(C)} = G_B^{(h)} + C_B, \quad (6)$$

而不是单独的 C_B 。三个对象分别对应 logit 目标分量、辅助分支主干梯度和包含硬主任务的完整公共主干梯度, 后续不混用。

实现仅计算一次软交叉熵, 并在软分支返回共享主干的隐藏梯度处施加路由。Routed-HMSA 与直接残差阻断臂 (Direct-Residual-Blocked, DRB) 在全局裁剪前分别向共享主干传入 $G_B^{(h)} + C_B + R_B$ 与 $G_B^{(h)} + C_B$ 。DRB 仅阻断残差在当前反向窗口中经辅助分支直接进入共享主干; 软头仍由完整软交叉熵更新, 故残差可能经后续软头状态间接影响未来公共梯度。本比较不等价于从整个训练过程中移除评分分歧。两臂分别训练后, 共享主干状态会随训练轨迹分化; 又因二者随后分别执行全局范数裁剪, 残差还可能通过改变裁剪系数间接缩放其他参数梯度。因此, 该比较识别的是加入直接残差路由后的整体训练效应, 而不是孤立参数块上的严格加性因果效应。其他探索性路由端点见补充材料。

4.4 残差几何分解

在每个优化器累积窗口结束后 (包括常规 32 微批窗口与固定轮末窗口), 以式(6)的全局裁剪前公共主干梯度 $G_B^{(C)}$ 为投影基准, 将残差主干梯度分解为

$$R_{B,\parallel} = \frac{\langle R_B, G_B^{(C)} \rangle}{\|G_B^{(C)}\|_2^2} G_B^{(C)}, \quad (7)$$

$$R_{B,\perp} = R_B - R_{B,\parallel}. \quad (8)$$

当 $\|G_B^{(C)}\|_2 = 0$ 时, 投影系数按预设实现定义为零。所有内积和范数以 FP64 累加, 分量写回模型梯度后再检查有限性、重构误差和归一化正交误差。Parallel-only 使用 $G_B^{(C)} + R_{B,\parallel}$, 用于检验沿公共方向的加速或减速; Orthogonal-only 使用 $G_B^{(C)} + R_{B,\perp}$, 用于检验转向新参数方向。完整更新随后仍经过原标准全局范数裁剪和 AdamW; 软头与硬头保留原损失更新。图2给出示意。这里的“正交”严格指当前完整累积窗口、全局裁剪前的主干参数梯度, 不表示 AdamW 更新或函数空间变化与公共路径正交。




图 2 软辅助目标与主干残差几何。(a) 辅助头 logit 梯度由主目标重复项和残差构成；(b) 经向量-雅可比累积后的残差主干梯度，相对于包含硬主任务的公共主干梯度分为平行与正交分量。右图各向量从同一原点出发，浅色虚线构成分解平行四边形，直角标记表示 $R_{B,\perp} \perp G_B^{(C)}$ ；箭头长度不表示实测范数。

4.5 范数-正交约束匹配的样本错配

仅比较原始残差与普通置换会同时改变范数、投影和裁剪行为。令 $I_y = \{i : y_i = y\}$, $\mathfrak{S}(I_y)$ 为该硬标签层内的双射集合，最大错配映射定义为

$$\pi_y^* \in \operatorname{argmax}_{\pi \in \mathfrak{S}(I_y)} \sum_{i \in I_y} \mathbb{I}(d_i \neq d_{\pi(i)}). \quad (9)$$

设该层共有 n 条记录，最大软目标类型频数为 $c_{\max}$ ，则任一双射至少保留 $\max(0, 2c_{\max} - n)$ 个同类型配对，最大可改变数为 $n - \max(0, 2c_{\max} - n)$ 。实现按软目标和不可变记录标识 (record ID) 排序，再将供体序列循环移动最大目标块的大小；该构造达到上述上界，同时保持硬标签分层内的软目标多重集不变。上界证明、并列处理和实现伪代码见补充材料，映射只读取训练集标签。

在某一处理臂当前模型状态和当前累积窗口内，分别计算原始样本-残差配对的梯度 R_B^A 、错配残差梯度 R_B^π 及该臂的公共梯度 $G_B^{(C)}$ ，再得到

$$R_B^{A,\perp} = R_B^A - \operatorname{proj}_{G_B^{(C)}}(R_B^A), \quad (10)$$

$$R_B^{\pi,\perp} = R_B^\pi - \operatorname{proj}_{G_B^{(C)}}(R_B^\pi), \quad (11)$$

$$\widetilde{R}_B^{\pi,\perp} = \frac{\|R_B^{A,\perp}\|_2}{\|R_B^{\pi,\perp}\|_2} R_B^{\pi,\perp}. \quad (12)$$

若两个正交范数均为零，缩放系数定义为零；若分母为零而分子非零，则实现立即停止。两个候选分量均与同一 $G_B^{(C)}$ 正交且范数相同，因而在 FP32 构造空间中具有相同的候选总梯度范数；除式 (12) 的范数匹配外不再施加人为缩放。本文将这一控制称为“范数-正交约束匹配”，其等价性只在各处理臂当前模型状态和累积窗口内成立，不包含曲率、历史梯度、AdamW 动量或跨训练轨迹几何。

5 实验设置

5.1 训练配置与受控变量

EduBench 使用同一冻结的 Qwen3-Reranker-0.6B [34] 本地快照与 Hugging Face 序列分类实现；模型、tokenizer 和精确输入模板的可核验标识见补充材料。最大输入长度为 2,048；以 BF16（16 位脑浮点格式）进行全参数微调，梯度几何标量用 FP64（64 位浮点格式）累加。优化器为 PyTorch AdamW，学习率 2×10^{-5} 、权重衰减 0.01， $\beta = (0.9, 0.999)$ 、 $\epsilon = 10^{-8}$ ；余弦调度的预热比例为 0.05。物理微批量为 4，每 32 个微批执行一次优化器更新，全局梯度范数裁剪阈值为 1.0。交叉熵先在每个物理微批内对样本取均值，再固定除以 32。通常累积窗口含 128 条样本；EduBench 每轮末窗口含 24 个微批、94 条样本，其中最后一个 2 样本微批内的单条样本权重是普通 4 样本微批的两倍。该规则在所有配对方法间一致，但使绝对训练轨迹依赖当前批划分。模型启用梯度检查点。主要性能比较使用预定随机种子 42–44，训练 10 轮，每轮在开发集评估；按硬头精确匹配率选择检查点，并列时选择更早轮次。所有配对比较共享输入、初始化规则、数据顺序、优化器与调度器。

主目标–残差与残差几何比较使用随机种子 42–46，并沿用相同的标准裁剪设置。种子 42–44 参与了假设形成，45–46 仅用于后续稳健性扩展，故五种子结果不是独立确认。正文统一比较第 10 轮，并报告第 1 至 10 轮开发集轨迹汇总；各臂独立选择检查点的结果只作为补充材料中的探索性分析。

EduBench 范数–正交匹配错配使用种子 47–49，Soft-STS-15 使用种子 61–63；二者均比较固定第 10 轮的模型。EduBench 与 Soft-STS-15 的训练集实际错配率分别为 94.65% 和 89.25%，且在每个硬标签层达到理论最大错配数；分层明细见补充材料。Soft-STS-15 的最大输入长度为 256；其每轮共有 37 个完整累积窗口，末窗口含 31 个 4 样本微批和一个 2 样本微批，共 126 条样本，并沿用上述固定 1/32 缩放。其连续点预测为硬头六类概率的期望，软头在推理时删除。

范数–正交匹配臂依次完成微批梯度累积、原始/错配残差捕获、投影与范数匹配、处理梯度写回、全局范数裁剪和 AdamW 更新。所有配对处理臂共享数据顺序、累积规则与上述微批加权方式；数值约束误差见补充材料。

5.2 指标与统计口径

EduBench 主指标为：(1) 整数预测与人类均分的平均绝对误差 (mean absolute error, MAE)；(2) 整数预测与量化硬标签的精确匹配率；(3) 整数预测与人类均分的 Kendall τ_b 。有符号偏差定义为 $n^{-1} \sum_i (\hat{y}_i - \bar{r}_i)$ ，正值表示高估。三档一致率先将 1–2、3、4–5 映射为低分、中分和高分档，再计算预测与量化硬标签处于同一档的比例。其他辅助指标包括二次加权 Kappa (quadratic weighted kappa, QWK)、分等级召回和低到高严重误判 (low-to-high, L2H，即真实标签不高于 2 而预测至少为 4)。Soft-STS-15 主指标为归一化平均绝对误差 (normalized MAE, NMAE)，即硬头期望分数与人类均分的 MAE 除以标签跨度 5；Spearman 也使用概率期望。精确匹配率与 QWK 使用六类 argmax 和量化硬标签，避免对连续期望任意取整。跨任务检验以 NMAE 为主指标。

测试访问前将平均 $\Delta\text{NMAE} \leq -0.00125$ 设为本研究预设最小报告幅度，等价于原始 0–5 尺度上的 MAE 改善 0.00625。该值由研究者在未知测试结果时预先指定，用于防止把任意微小的同向差值判为达到预设标准；它既非理论推导值，也没有外部最小可感知效应依据，因而只服务于本次检验，不代表通用实践阈值。完整六项判据、冻结说明和一次性测试访问记录见补充材料。

主结果中的均值 $\pm$ 样本标准差描述训练种子差异，不是置信区间。作为辅助比较，EduBench 条目级区间先在每条测试记录上平均三个训练种子的配对误差差值，再以 2,218 条记录为重采样单元，有放回抽取与原记录数相同的记录；重复 10,000 次并取 2.5% 与 97.5% 分位数。考虑同一问题内相关性时，则把共享同一原始问题标识的全部记录作为问题簇；Soft-STS-15 把共享任一句子的连通句对作为成分簇。两种簇级区间均有放回抽取与原簇数相同的簇，保留抽中簇的全部条目，以条目加权均值为统计量，同样重复 10,000 次并取 2.5% 与 97.5% 分位数。问题簇区间是 EduBench 的主要稳健性结果。所有区间只反映固定已训练模型下的评测单元组成不确定性，不能替代更多训练种子。

5.3 实现有效性与评估范围

Routed-HMSA 与普通 HMSA 使用相同前向输出和 $\mathcal{L}_{\text{hard}} + \mathcal{L}_{\text{soft}}$ 目标；前者只在辅助隐藏状态的反向路径插入恒等路由，以便随后替换目标分量。无更新诊断支持固定模型状态下的局部目标对应，条件与数值误差见补充材料。然而，双方在开发集上按同一规则选择的种子 42 检查点只有 89.76% 预测一致率，MAE 绝对差为 0.003514，未通过预设等价判据；三个共同种子固定第 10 轮的端点均值接近，也不能替代轨迹等价。因此，后续机制结论只针对受控路由实现，不解释普通 HMSA 的完整训练轨迹。

EduBench 的测试集仅用于 Hard-only 与 HMSA 的主要性能比较；置换、连续均分、主目标-残差、残差几何和样本-残差配对分析均在开发集上完成。固定第 10 轮与全轨迹分析消除了各臂独立选择检查点这一偏差来源；由于研究假设也在同一开发集上逐步形成，二者均作为内部稳健性分析。Soft-STS-15 的数据划分、错配映射、训练设置、六项判据和分析方法在测试评估前冻结；首次测试评估后不增加种子、更换轮次或改用其他主指标。

6 结果

6.1 总体评分性能

表2显示，在三个预定随机种子上，HMSA 相对 Hard-only 均降低测试 MAE，并提高精确匹配率与 Kendall τ_b 。平均而言，MAE 从 0.433 ± 0.009 降至 0.388 ± 0.003 ，精确匹配率从 0.731 ± 0.001 提升至 0.749 ± 0.002 ，Kendall τ_b 从 0.561 ± 0.018 提升至 0.611 ± 0.004 ；逐种子变化见图3。条目级配对自助重采样的 MAE 差值为 -0.0448 ，95% 区间为 $[-0.0565, -0.0339]$ ；以 163 个问题簇为单位进行重采样时，区间为 $[-0.0622, -0.0300]$ 。逐种子测试结果见补充材料。

HMSA 将平均 L2H 从 59.7 降至 37.3，在固定 103 个低分条目中的严重高估率从 57.9% 降至 36.2%；QWK 从 0.522 升至 0.651，三档一致率从 0.879 升至 0.890。1-4 分召回均提高，5 分召回从 0.869 轻微降至 0.864，因此不作“所有等级均改善”的概括。逐种子与分等级结果见补充材料。

表 2 EduBench 测试集结果 ($n = 2,218$; 其中低分条目 $n = 103$)。检查点按开发集精确匹配率选择; 均值与样本标准差由三个训练随机种子计算, 差值为 HMSA–Hard-only, 并由未四舍五入的逐种子结果计算。L2H 数量为跨种子均值, 因而可为小数; 粗体表示每项描述性均值较优。

指标	Hard-only	HMSA	Δ
MAE ↓	0.433 ± 0.009	0.388 ± 0.003	-0.045
精确匹配率 ↑	0.731 ± 0.001	0.749 ± 0.002	+0.019
Kendall τ_b ↑	0.561 ± 0.018	0.611 ± 0.004	+0.050
有符号偏差 (0 最佳)	0.200 ± 0.051	0.146 ± 0.033	-0.054
三档一致率 ↑	0.879 ± 0.005	0.890 ± 0.003	+0.011
L2H 数量 ↓	59.7 ± 12.7	37.3 ± 1.5	-22.3
L2H 比率 ↓	0.579 ± 0.123	0.362 ± 0.015	-0.217
QWK ↑	0.522 ± 0.055	0.651 ± 0.016	+0.129




图 3 EduBench 测试集三个训练种子的配对结果。细线表示单个种子, 粗线表示种子均值; 各面板使用局部纵轴, 不以视觉跨度比较跨指标效应量。

6.2 单头与粗粒度替代对照

在开发集三个种子上, Shuffled-soft 相对 Hard-only 的平均 MAE、精确匹配率和 Kendall 分别变化 -0.004 、 $+0.003$ 和 $+0.008$, 说明一般双头训练或类别条件软目标先验可能贡献部分收益; 恢复真实样本-分布对应后, HMSA 相对 Shuffled-soft 的三项差值进一步为 -0.010 、 $+0.009$ 和 $+0.020$ 。该置换仅使 56.14% 的条目改变软目标, 因而不是完全控制。MeanAux 的 MAE、精确匹配率和 Kendall 分别为 0.395 ± 0.009 、 0.710 ± 0.003 和 0.569 ± 0.006 ; 相对 MeanAux, HMSA 的三项指标分别变化 -0.016 、 $+0.021$ 和 $+0.028$ 。由于均分与分布在 EduBench 中一一对应, 这一差异只能归因于当前目标参数化与损失所诱导的训练行为, 而非额外标签信息。作为补充诊断, 单种子 Direct-soft 未优于 Hard-only, 固定 0.5 混合目标仅带来较小 MAE 差值; 这些固定配置不用于评价整个单头软监督方法族。逐种子结果与单种子诊断见补充材料。

表 3 EduBench 开发集逐种子第 10 轮 ΔMAE 与轨迹积分摘要。差值为处理组减直接残差阻断臂 (DRB)，负值表示改善；第 10 轮结果不进行独立检查点选择。轨迹积分的定义与全部逐轮数值见补充材料。种子 42–44 参与假设形成，因此本表属于内部稳健性证据。

处理组	统计量	种子 42	种子 43	种子 44	种子 45	种子 46	均值
完整残差	第 10 轮	-0.0281	-0.0276	-0.0110	-0.0397	-0.0030	-0.0219
	第 1 至 10 轮轨迹	-0.0192	-0.0260	-0.0070	-0.0189	-0.0113	-0.0165
正交残差	第 10 轮	-0.0261	-0.0156	-0.0146	-0.0156	+0.0065	-0.0131
	第 1 至 10 轮轨迹	-0.0074	-0.0224	-0.0058	-0.0124	-0.0075	-0.0111
平行残差	第 10 轮	-0.0075	+0.0105	+0.0070	-0.0161	+0.0085	+0.0005
	第 1 至 10 轮轨迹	+0.0097	+0.0049	+0.0020	-0.0107	+0.0020	+0.0016

6.3 固定轮次下的残差增量

表3给出逐种子第 10 轮差值与预定义轨迹积分摘要。Routed-HMSA 相对 DRB 的第 10 轮平均 ΔMAE 为 -0.0219 ，五个种子均为负，精确匹配率和 Kendall τ_b 平均提高 0.0093 和 0.0334；作为描述性轨迹统计，50 个相关的种子-轮次单元中 42 个差值为负，归一化梯形积分均值为 -0.0165 。因此，该差值不依赖各臂独立选择检查点这一具体做法。逐轮数值、积分公式与其他探索性端点见补充材料。

6.4 当前全局裁剪制度下的正交路由结果

标准裁剪设置下，Orthogonal-only 相对 DRB 在第 10 轮的 4/5 种子上降低 MAE，平均差值为 -0.0131 ；其第 1 至 10 轮轨迹积分均值为 -0.0111 。Parallel-only 的对应差值为 $+0.0005$ 和 $+0.0016$ 。因此，Orthogonal-only 臂在当前路由制度下保留了完整残差臂的部分平均差值，而 Parallel-only 臂未复现平均改善；各臂沿独立轨迹训练，不能据此作加性分解。

训练过程统计显示，正交轨迹中 $\|R_\perp\|/\|R\|$ 的中位数为 0.772， $\cos(R, G_C)$ 的中位数为 -0.635 ，且全部 1,050 个步骤均触发全局裁剪。因此，处理同时改变裁剪前方向、范数和裁剪系数，不能解释为与尺度无关的纯方向因果效应。共同缩放控制又在 8.10% 步骤触发安全上限，未维持预定几何条件；逐步统计与失败控制见补充材料。

6.5 样本配对效应较小

在 EduBench 种子 47–49 的固定第 10 轮比较中，样本自身正交残差相对范数-正交约束匹配错配残差的 MAE 差值为 -0.0040 、 -0.0050 和 -0.0226 ，平均为 -0.0105 ；问题簇自助重采样区间为 $[-0.0243, +0.0029]$ ，该区间跨越零。

Soft-STs-15 的测试结果见表4。




图 4 残差路由与跨任务样本配对效应。左图使用 EduBench 五个种子的固定第 10 轮结果：空心圆为单个种子，实心菱形为第 10 轮均值，空心方形为第 1 至 10 轮归一化梯形积分均值；负值表示改善。右图条件于 Soft-STIS-15 三个固定训练种子，点与线分别为跨种子平均差值和句子成分簇自助重采样 95% 区间；点线为测试评估前设定的最小报告幅度。两个面板的指标尺度不同。

表 4 Soft-STIS-15 测试结果（三个训练随机种子的均值 $\pm$ 样本标准差）。NMAE、MAE 与 Spearman 使用硬头概率期望；精确匹配率和 QWK 使用硬头 $\arg \max$ 与量化硬标签。NMAE 为 MAE 除以标签跨度 5。“匹配错配”与“样本自身”分别表示范数-正交约束匹配的错配残差和样本自身正交残差。粗体仅表示描述性均值最优；是否达到本研究预设最小报告幅度另由补充材料中的六项判据表判定。

方法	NMAE $\downarrow$	MAE $\downarrow$	Spearman $\uparrow$	精确匹配率 $\uparrow$	QWK $\uparrow$
量化均值	0.0872 $\pm$ 0.0012	0.4360 $\pm$ 0.0061	0.9252 $\pm$ 0.0014	0.6305 $\pm$ 0.0071	0.9078 $\pm$ 0.0032
匹配错配	0.0856 $\pm$ 0.0009	0.4280 $\pm$ 0.0045	0.9239 $\pm$ 0.0014	0.6284 $\pm$ 0.0022	0.9079 $\pm$ 0.0009
样本自身	0.0846 $\pm$ 0.0008	0.4229 $\pm$ 0.0039	0.9276 $\pm$ 0.0002	0.6278 $\pm$ 0.0092	0.9085 $\pm$ 0.0021

样本自身正交残差的平均 NMAE 为 0.08459，优于范数-正交约束匹配错配残差的 0.08561 和量化均值主目标的 0.08720。样本自身减错配残差的平均 Δ NMAE 为 -0.0010207，句子成分簇自助重采样区间为 $[-0.001833, -0.000228]$ ，三个种子的差值均为负，Spearman 平均提高 0.00366。精确匹配率则由错配残差的 0.6284 轻微降至 0.6278，且低于量化主目标的 0.6305，说明该增量主要体现在连续误差与排序，而非整数类别命中率。

在固定这三个训练种子的条件下，负向差值对测试簇重采样保持稳定；该区间不包含重新训练的不确定性。其绝对改善幅度 0.0010207 低于本研究预设最小报告幅度 0.00125，六项判据满足五项，故未达到预设确认标准。完整判据和逐种子结果见补充材料。

7 讨论

结果形成三个相互区分的证据层次：普通 HMSA 在 EduBench 固定划分的三个预定种子上均改善测试集硬头评分；受控路由在同一开发集上显示完整残差臂相对 DRB 获得平均改善，Orthogonal-only 臂保留其中一部分平均差值；样本-残差配对虽呈现有利方向，但 EduBench 区间跨零，Soft-STIS-15 的幅度也低于本研究预设最小报告幅度。因而，本文不作“人类分歧普遍有用”的概括，也不把路由结果视为普通 HMSA 的完整因果解释。

在当前路由训练制度中，第二硬任务和 **Parallel-only** 均不能复现完整残差臂的平均改善，这使残差引入的参数梯度方向成为值得进一步检验的机制候选。该比较只控制残差当前窗口直接进入共享主干的路径，软头仍由完整软交叉熵更新；加之全部几何实验步骤均触发全局裁剪且共同缩放控制未维持预设条件，现有结果反映直接路由、方向、范数、裁剪系数和 AdamW 轨迹的联合变化，而非与尺度和优化器状态无关的纯方向因果效应。

簇级区间与预设最小报告幅度回答不同问题：前者衡量固定训练模型下结果对评测簇组成的稳定性，后者是本研究在未知测试结果时预先规定的报告门槛。**Soft-STS-15** 的区间低于零但未达到该门槛，说明统计可辨别性不能替代本研究预先规定的最小报告幅度。**HMSA** 推理时删除软头，不增加部署接口；但低分召回仍然有限，本文不将其视为低分检测的完整解决方案。

8 局限性

- (1) 所有模型实验均使用 **Qwen3-Reranker-0.6B**，尚未验证参数规模与架构变化；**Soft-STS-15** 也不是第二个教育评分数据集。
- (2) **EduBench** 的机制假设与主要检验使用同一开发集，且普通 **HMSA** 与 **Routed-HMSA** 未通过完整轨迹等价检验；固定轮次只消除了独立选点偏差，路由结果既非独立确认，也不能解释普通 **HMSA** 的全部测试增益。
- (3) **EduBench** 的评分模式仅包含完全一致或相邻等级 2:1，经验分布与均分一一对应；结果不支持“分布包含更多标签信息”的主张。
- (4) 几何量定义在裁剪前参数梯度空间，全部步骤均触发全局裁剪且 AdamW 继续参与更新；簇级区间又条件于有限训练种子，轮末微批权重依赖当前批划分。这些因素限制了方向因果解释与外部推广。

9 结论

本文首先在 **EduBench** 固定划分的三个预定种子上观察到 **HMSA** 对测试评分指标的同向改善。随后，通过软辅助交叉熵的主目标-残差分解和共享主干受控路由，完整残差臂相对 **DRB** 获得开发集平均差值，正交残差保留其中一部分，而平行残差未复现该现象。样本-残差配对差值在 **EduBench** 上区间跨零，在 **Soft-STS-15** 上又低于本研究预设最小报告幅度。因此，本文识别的是当前路由、全局裁剪和独立训练制度下的机制候选及其边界，而非普通 **HMSA** 测试增益的加性或方向性因果分解。

参考文献

- [1] Xu, B., Bai, Y., Sun, H., Lin, Y., Liu, S., Liang, X., Li, Y., Dong, Z., Zhang, J., Deng, Y., Zou, X., Gao, Y., and Huang, H. **EduBench: A comprehensive benchmarking dataset for evaluating large language models in diverse educational scenarios**. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 21615–21645, 2026. doi:10.18653/v1/2026.acl-long.987.
- [2] Plank, B. The problem of human label variation: On ground truth in data, modeling and evaluation. In *Proceedings of EMNLP*, pp. 10671–10682, 2022.

- [3] Mostafazadeh Davani, A., Díaz, M., and Prabhakaran, V. Dealing with disagreements: Looking beyond the majority vote in subjective annotations. *Transactions of the Association for Computational Linguistics*, 10:92–110, 2022.
- [4] Uma, A., Fornaciari, T., Hovy, D., Paun, S., Plank, B., and Poesio, M. Learning from disagreement: A survey. *Journal of Artificial Intelligence Research*, 72:1385–1470, 2021.
- [5] Fornaciari, T., Uma, A., Paun, S., Plank, B., Hovy, D., and Poesio, M. Beyond black & white: Leveraging annotator disagreement via soft-label multi-task learning. In *Proceedings of NAACL-HLT*, pp. 2591–2597, 2021. doi:10.18653/v1/2021.naacl-main.204.
- [6] Zheng, L., Chiang, W.-L., Sheng, Y., et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems*, 2023.
- [7] Gu, J., Jiang, X., Shi, Z., et al. A survey on LLM-as-a-judge. *The Innovation*, 7(6):101253, 2026. doi:10.1016/j.xinn.2025.101253.
- [8] Maurya, K. K., Srivatsa, K. A., Petukhova, K., and Kochmar, E. Unifying AI tutor evaluation: An evaluation taxonomy for pedagogical ability assessment of LLM-powered AI tutors. In *Proceedings of NAACL-HLT*, pp. 1234–1251, 2025.
- [9] Macina, J., Daheim, N., Hakimi, I., Kapur, M., Gurevych, I., and Sachan, M. MathTutorBench: A benchmark for measuring open-ended pedagogical capabilities of LLM tutors. In *Proceedings of EMNLP*, pp. 204–221, 2025.
- [10] Li, H., Dong, Q., Chen, J., et al. LLMs-as-judges: A comprehensive survey on LLM-based evaluation methods. arXiv preprint arXiv:2412.05579, 2024.
- [11] Tian, Z., Han, Z., Chen, Y., Xu, H., Yang, X., Xuan, R., Wang, H., and Liao, L. Overconfidence in LLM-as-a-judge: Diagnosis and confidence-driven solution. arXiv preprint arXiv:2508.06225, 2025.
- [12] Peterson, J. C., Battleday, R. M., Griffiths, T. L., and Russakovsky, O. Human uncertainty makes classification more robust. In *Proceedings of ICCV*, 2019.
- [13] Uma, A., Fornaciari, T., Dumitrache, A., et al. SemEval-2021 Task 12: Learning with disagreements. In *Proceedings of SemEval-2021*, pp. 338–347, 2021.
- [14] Leonardelli, E., Abercrombie, G., Almanea, D., et al. SemEval-2023 Task 11: Learning with disagreements (LeWiDi). In *Proceedings of SemEval-2023*, pp. 2304–2318, 2023.
- [15] Kurniawan, K., Mistica, M., Baldwin, T., and Lau, J. H. Training and evaluating with human label variation: An empirical study. *Computational Linguistics*, 52(1):85–111, 2026. doi:10.1162/coli.a.578.
- [16] Sandri, M., Leonardelli, E., Tonelli, S., and Jezek, E. Why don’t you do it right? Analysing annotators’ disagreement in subjective tasks. In *Proceedings of EACL*, pp. 2428–2441, 2023.
- [17] Weber-Genzel, L., Peng, S., de Marneffe, M.-C., and Plank, B. VariErr NLI: Separating annotation error from human label variation. In *Proceedings of ACL*, pp. 2256–2269, 2024.
- [18] Rodríguez-Barroso, N., Martínez Cámara, E., Camacho Collados, J., Luzón, M. V., and Herrera, F. Federated learning for exploiting annotators’ disagreements in natural language processing. *Transactions of the Association for Computational Linguistics*, 12:630–648, 2024.
- [19] Gheibi, M. and Ghazizadeh, G. Same target, different basins: Hard vs. soft labels for annotator distributions. arXiv preprint arXiv:2605.20642, 2026.
- [20] Caruana, R. Multitask learning. *Machine Learning*, 28:41–75, 1997.

- [21] Yu, T., Kumar, S., Gupta, A., Levine, S., Hausman, K., and Finn, C. Gradient surgery for multi-task learning. In *Advances in Neural Information Processing Systems*, 2020.
- [22] Liu, B., Liu, X., Jin, X., Stone, P., and Liu, Q. Conflict-averse gradient descent for multi-task learning. In *Advances in Neural Information Processing Systems*, 2021.
- [23] Wang, Z., Tsvetkov, Y., Firat, O., and Cao, Y. Gradient vaccine: Investigating and improving multi-task optimization in massively multilingual models. In *Proceedings of ICLR*, 2021.
- [24] Du, Y., Czarnecki, W. M., Jayakumar, S. M., Farajtabar, M., Pascanu, R., and Lakshminarayanan, B. Adapting auxiliary losses using gradient similarity. arXiv preprint arXiv:1812.02224, 2018.
- [25] Dery, L. M., Dauphin, Y., and Grangier, D. Auxiliary task update decomposition: The good, the bad and the neutral. In *Proceedings of the 9th International Conference on Learning Representations*, 2021.
- [26] Jiang, J., Chen, B., Pan, J., Wang, X., Liu, D., Jiang, J., and Long, M. ForkMerge: Mitigating negative transfer in auxiliary-task learning. In *Advances in Neural Information Processing Systems*, 2023.
- [27] Hsieh, Y.-G., Thornton, J., Ndiaye, E., Klein, M., Cuturi, M., and Ablin, P. Careful with that scalpel: Improving gradient surgery with an EMA. In *Proceedings of the 41st International Conference on Machine Learning*, PMLR 235:19085–19100, 2024.
- [28] Diaz, R. and Marathe, A. Soft labels for ordinal regression. In *Proceedings of CVPR*, pp. 4738–4747, 2019.
- [29] Li, Q., Wang, J., Yao, Z., Li, Y., Yang, P., Yan, J., Wang, C., and Pu, S. Unimodal-concentrated loss: Fully adaptive label distribution learning for ordinal regression. In *Proceedings of CVPR*, pp. 20513–20522, 2022.
- [30] Wen, C., Zhang, X., Yao, X., and Yang, J. Ordinal label distribution learning. In *Proceedings of ICCV*, pp. 23481–23491, 2023.
- [31] Nachmani, I., Genossar, B., Scharf, C., Shraga, R., and Gal, A. SLACE: A monotone and balance-sensitive loss function for ordinal regression. In *Proceedings of AAAI*, pp. 19598–19606, 2025.
- [32] Agirre, E., Banea, C., Cardie, C., Cer, D., Diab, M., Gonzalez-Agirre, A., Guo, W., Lopez-Gazpio, I., Maritxalar, M., Mihalcea, R., Rigau, G., Uria, L., and Wiebe, J. SemEval-2015 Task 2: Semantic textual similarity, English, Spanish and pilot on interpretability. In *Proceedings of the 9th International Workshop on Semantic Evaluation (SemEval 2015)*, pp. 252–263, 2015. doi:10.18653/v1/S15-2045.
- [33] Benito-Santos, A. and Ghajari, A. Beyond averages: Learning with annotator disagreement in STS. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pp. 35551–35557, 2025. doi:10.18653/v1/2025.emnlp-main.1800.
- [34] Zhang, Y., Li, M., Long, D., Zhang, X., Lin, H., Yang, B., Xie, P., Yang, A., Liu, D., Lin, J., Huang, F., and Zhou, J. Qwen3 Embedding: Advancing text embedding and reranking through foundation models. arXiv preprint arXiv:2506.05176, 2025.